Ejercicio U04.E07: “Evaluación de impacto y auditoría de equidad”.

«Una métrica no declara justicia: evidencia, incertidumbre y una decisión que alguien firma»

Por:
Melvin H. Rivas Genao
Matrícula 100279298

Ejercicio Presentado a la
Escuela de Informática, Facultad de Ciencias, División de Postgrado y Educación Permanente, Como Cumplimiento del Curso “Ciencia de Datos II” (INF-8239),
Unidad 04: Ética y Roles en Ciencia de Datos,
Maestría en Ciencia de Datos e Inteligencia Artificial,
Edwin Ramón José Nolasco.

Universidad Autónoma de Santo Domingo (UASD)
Santo Domingo de Guzmán, D.N.
Noviembre de 2026

Contenido

Ejercicio U04.E07: Evaluación de impacto y auditoría de equidad. Expediente de LAB11 y LAB12 1
Objetivo 1
Alcance del trabajo 1
Introducción 2
Finalidad, interesados y proporcionalidad 2
Finalidad y decisión asistida 2
Interesados 3
Necesidad y proporcionalidad 3
Marco normativo: obligación legal, marco voluntario y recomendación ética 4
Registro de riesgos y NIST AI RMF 5
Riesgos priorizados 5
Funciones del NIST AI RMF 6
Auditoría de equidad 6
Datos, corte temporal y baseline 6
Resultados global y por grupo 6
Incertidumbre de las brechas 7
Auditoría interseccional 8
Mitigación y trade-offs 8
Decisión final: limitar 9
Pruebas, reproducibilidad y repositorio 10
Declaración de uso de inteligencia artificial 10
Conclusiones 12
Referencias 13
Apéndice. Repositorio del proyecto 15

Ejercicio U04.E07: Evaluación de impacto y auditoría de equidad. Expediente de LAB11 y LAB12

Objetivo

Integrar de forma individual las evidencias de LAB11 (evaluación de impacto ético) y LAB12 (auditoría de equidad con Fairlearn) en un expediente verificable y aplicable al trabajo final. El expediente debe permitir que otra persona compruebe cada afirmación en el repositorio y entienda por qué el sistema se limita y no se despliega sin condiciones.

Alcance del trabajo

El caso es el sistema sintético del curso, *Territorial Review DSS*, que sugiere el orden en que un equipo técnico revisa casos territoriales. La rúbrica se atiende con los siguientes artefactos editables, todos en el repositorio:

- **Finalidad, interesados y proporcionalidad:** ficha de propósito, tabla de interesados con poder y daño, alternativa no predictiva y usos prohibidos.
- **Registro de riesgos y NIST AI RMF:** once riesgos con control, responsable, evidencia, riesgo residual, función del marco NIST y tipo de norma.
- **Auditoría global, por grupo e interseccional:** métricas con conteos, intervalos de confianza por bootstrap y una regla de soporte mínimo.
- **Mitigación, trade-offs y decisión:** siete candidatos comparados con las puertas del curso y un registro de decisión firmado.
- **Pruebas, referencias y declaración de IA:** 24 pruebas automáticas, matriz normativa con fuentes y declaración de uso de IA.

Introducción

Una evaluación de impacto no pregunta solo si un modelo funciona. Pregunta qué decisión modifica, quién gana y quién puede perder, qué alternativa menos invasiva existe y bajo qué condición debe detenerse. Una auditoría de equidad, a su vez, no convierte una métrica en una declaración de justicia: no existe una única definición correcta de equidad y, cuando los grupos tienen tasas base distintas, no es posible igualar a la vez todas las tasas de error (Chouldechova, 2017; Kleinberg et al., 2017). La métrica pertinente depende del daño que se quiere evitar.

Por eso este expediente separa con cuidado tres tipos de afirmaciones. Las **obligaciones legales**, que no dependen de la voluntad del analista; los **marcos voluntarios**, que ordenan el trabajo pero no obligan; y las **recomendaciones éticas**, que son decisiones propias y deben defenderse como tales. La IA generativa apoyó la estructura, el código y la redacción, pero los valores del análisis (qué daño priorizar, cuánta brecha tolerar y qué decidir) los fijó el estudiante a partir de la evidencia.

El documento describe primero la finalidad del sistema y sus interesados, luego el marco normativo y el registro de riesgos, después la auditoría global, por grupo e interseccional, las mitigaciones evaluadas y la decisión final. Cierra con las pruebas, la declaración de uso de inteligencia artificial y las conclusiones.

Finalidad, interesados y proporcionalidad

Finalidad y decisión asistida

Tabla 1

Ficha de propósito del sistema (resumen de lab11_impact.yml)

Elemento	Definición
Finalidad	Sugerir el orden de revisión humana de casos territoriales sintéticos
Decisión asistida	Qué casos revisa primero un analista; ningún caso se descarta ni se decide automáticamente
Usuarios	Analistas y revisores técnicos de la unidad territorial
Población afectada	Personas y comunidades de los casos, en especial los grupos G1 y G2 y las bandas de edad
Propietario	Institutional Owner y Product Owner, según la matriz RACI

Elemento	Definición
Alternativa no predictiva	Orden de llegada con regla transparente: priorizar si hay 3 o más incidentes previos
Usos prohibidos	Intervención automática, elegibilidad, emergencia, usar el grupo para decidir, perfilar y usar datos reales sin nueva evaluación
Apelación	Revisor distinto, respuesta en 5 días hábiles, con registro en bitácora

Nota. Texto completo en *student_inputs/lab11_impact.yml*. La condición de retiro se presenta en la sección de decisión.

Interesados

Tabla 2

Interesados, poder y mecanismo de participación

Interesado	Poder	Daño posible	Participación
Persona afectada	bajo	Revisión retrasada si el modelo no la detecta (FN), o escrutinio innecesario (FP)	Aviso de uso de IA, derecho a pedir revisión humana (5 días hábiles)
Operador	medio	Sesgo de automatización: aceptar el orden sin criterio propio	Capacitación, registro de desacuerdos con el orden sugerido
Propietario institucional	alto	Daño reputacional y legal si el sistema discrimina o se usa fuera de alcance	Firma el registro de decisión, aprueba la ampliación del piloto
Equipo de datos	medio	Presión para presentar métricas favorables	Publica la auditoría por grupo e interseccional con intervalos
Representantes comunitarios	bajo	Exclusión si sólo opinan técnicos	Consulta antes de ampliar el piloto
Supervisor (DIGEIG / OGTIC)	alto	Supervisión tardía si el sistema no se registra	Registro del sistema

Nota. Versión abreviada; texto completo en *student_inputs/stakeholders.csv*.

La asimetría es la clave del análisis: la persona afectada es quien puede sufrir el daño más serio (una revisión retrasada) y es también quien menos poder tiene sobre el sistema. Por eso se le reconocen un aviso, una apelación con plazo y, antes de ampliar el piloto, una consulta a sus representantes.

Necesidad y proporcionalidad

¿Hace falta un modelo? La alternativa no predictiva, una regla que cualquier operador puede aplicar, alcanza un recall alto (0.837), pero lo logra marcando el 71 % de los casos, con tasas de falsas alertas de 0.52 en G1 y 0.63 en G2. En la práctica no ordena nada: satura la revisión. El modelo logístico ofrece un orden más útil con una intervención mínima: solo cambia el orden de

una cola que se revisa completa, no excluye a nadie y no usa el grupo protegido. Esa intervención es proporcional siempre que se mantengan la revisión humana total y la condición de retiro.

Marco normativo: obligación legal, marco voluntario y recomendación ética

La matriz normativa del repositorio clasifica cada instrumento según su fuerza y su aplicabilidad a este caso. La Tabla 3 la resume. A la fecha de este documento, la República Dominicana **no tiene una ley de inteligencia artificial aprobada**: hay proyectos en estudio en el Senado y en la Cámara de Diputados (Senado de la República Dominicana, 2026).

Tabla 3

Matriz normativa resumida

Instrumento	Tipo	¿Vinculante aquí?	Implicación en el sistema
Constitución, art. 39 (igualdad)	Obligación legal	Condicional	No usar el grupo protegido para decidir
Constitución, arts. 44 y 70; Ley 172-13 de datos personales	Obligación legal	Condicional (solo con datos reales)	Sin identificadores directos; derechos del titular
Decreto 787-26, Código de Ética de la IA para los Servicios Públicos	Obligación legal (administración pública)	Condicional (si lo opera una entidad pública)	Evaluación de impacto ético y de derechos previa, registro, revisión humana, prohibición del perfilamiento predictivo por residencia
ENIA (Decreto 498-23); proyectos de ley de IA	Marco voluntario / política	No	Contexto y seguimiento
NIST AI RMF 1.0; OCDE; UNESCO; Reglamento (UE) 2024/1689	Marco voluntario / referencia comparada	No	Organizan riesgos y supervisión humana
No usar el grupo al decidir; priorizar el falso negativo; no ocultar grupos pequeños	Recomendación ética	Sí (decisión propia)	Exclusión de ThresholdOptimizer, métrica principal y regla de soporte

Nota. Matriz completa con 13 filas y fuentes en *docs/NORMATIVE_MATRIX.csv*. El texto oficial del Decreto 787-26 no pudo descargarse del portal de la Presidencia; su descripción se apoya en fuentes secundarias concordantes y debe verificarse. Clasificación académica, no asesoría legal.

El caso más delicado es el **Decreto 787-26**, del 2 de noviembre de 2026. Aprueba un código de cumplimiento obligatorio para la administración pública cuando diseña, contrata o usa IA; exige una evaluación de impacto ético y de derechos antes de desplegar sistemas de alto impacto; reconoce el derecho a revisión humana y prohíbe, entre otros usos, el perfilamiento criminal predictivo basado en residencia, origen étnico o condición socioeconómica (Presidencia de la

República Dominicana, 2026). El sistema de este expediente no es penal y es sintético, por lo que el decreto no lo obliga hoy. Pero si una entidad pública lo adoptara, la evaluación y el registro serían obligatorios, y el uso de la variable territorial *zone* exigiría una revisión jurídica específica.

Registro de riesgos y NIST AI RMF

Riesgos priorizados

El registro contiene once riesgos. Los ocho primeros conservan la probabilidad y el impacto propuestos por la plantilla del curso y se redactaron con escenarios concretos y evidencia; los tres restantes (R09 a R11) se añadieron a partir de la auditoría. La prioridad es el producto de probabilidad e impacto (de 1 a 16), y sirve para ordenar la atención, no para convertir el daño humano en una verdad matemática.

Tabla 4

Seis riesgos de mayor prioridad (de once)

ID	Escenario	P × I	Control principal	Residual
R02	Más falsas alertas en G2	3 × 3 = 9	Una alerta sólo cambia el orden de revisión, nunca dispara una acción	medio
R01	Casos de riesgo real de G1 no se priorizan	2 × 4 = 8	Revisión humana de todos los casos	alto
R07	La variable zone actúa como proxy territorial o de residencia y deriva en perfilamiento de zonas	2 × 4 = 8	Uso sólo para ordenar revisiones, nunca para perfilar	alto
R11	Las conclusiones obtenidas con datos sintéticos se trasladan a datos reales sin nueva evaluación	2 × 4 = 8	Uso fuera de alcance declarado	medio
R03	Conclusiones erróneas sobre intersecciones pequeñas	2 × 3 = 6	Regla de soporte mínimo (n ≥ 20, ≥ 5 positivos y ≥ 5 negativos)	medio
R10	Una mitigación aleatorizada	2 × 3 = 6	No adoptada	bajo

Nota. Registro completo, con responsable, evidencia, función NIST y tipo de norma, en *student_inputs/risk_register.csv*; puntuado en *reports/lab11/risk_register_scored.csv*.

Los tres riesgos prioritarios se interpretan así. **R02**, el exceso de falsas alertas en G2, es el más probable, pero su daño se contiene porque una alerta solo cambia el orden de revisión y nunca dispara una acción. **R01**, los casos de riesgo real de G1 que no se priorizan, es el daño elegido como principal; su riesgo residual sigue alto porque, con 59 casos en G2, no puede descartarse que la

brecha real supere la tolerancia. **R07**, el uso de la zona como proxy territorial, es residual alto porque su mitigación obvia, quitar la variable, empeora otra brecha.

Funciones del NIST AI RMF

Tabla 5

Evidencia por función del NIST AI RMF 1.0

Función	Acciones realizadas	Evidencia en el repositorio
GOVERN	Propietario y RACI, usos prohibidos, matriz normativa, declaración de IA	raci.csv, governance.yml, NORMATIVE_MATRIX.csv
MAP	Finalidad, afectados, alternativa no predictiva; interesados; 11 riesgos	lab11_impact.yml, stakeholders.csv, risk_register.csv
MEASURE	Métricas globales, por grupo e interseccionales; IC por bootstrap; 7 candidatos con costo	reports/e07/*.csv
MANAGE	Decisión LIMITAR, retiro, apelación, monitoreo por ventanas	lab12_decision.yml, DECISION_RECORD.md

Nota. Generado en *reports/e07/rmf_summary.json*. Que un archivo exista no demuestra que el control sea eficaz: la eficacia se comprobará en el piloto (NIST, 2023).

Auditoría de equidad

Datos, corte temporal y baseline

El dataset sintético tiene 640 casos con una tasa positiva de 55.2 %. Los grupos son desiguales en tamaño (G1 396, G2 244) y en tasa base (G1 0.497, G2 0.639). El corte es temporal: se entrena hasta el 2026-09-24 (480 casos) y se prueba desde el 2026-09-25 (160 casos: 101 de G1 y 59 de G2), para no usar el futuro al evaluar el pasado. El grupo protegido se excluye del modelo y se conserva solo para auditar; excluirlo no elimina los sesgos indirectos que pueden transmitir otras variables. La auditoría usa MetricFrame de Fairlearn (Weerts et al., 2023).

Resultados global y por grupo

Tabla 6

Regresión logística del curso: métricas global y por grupo (prueba)

Métrica	Global	G1	G2	Brecha
Casos	160	101	59	—
Accuracy	0.719	0.703	0.746	0.043
Tasa de selección	0.531	0.446	0.678	0.232
Recall (métrica principal)	0.717	0.653	0.791	0.138
Precisión	0.776	0.711	0.850	0.139

Métrica	Global	G1	G2	Brecha
Tasa de falsos positivos	0.279	0.250	0.375	0.125

Nota. Fuente: *reports/lab12/logistic/global_metrics.json* y *fairness_by_group.csv*.

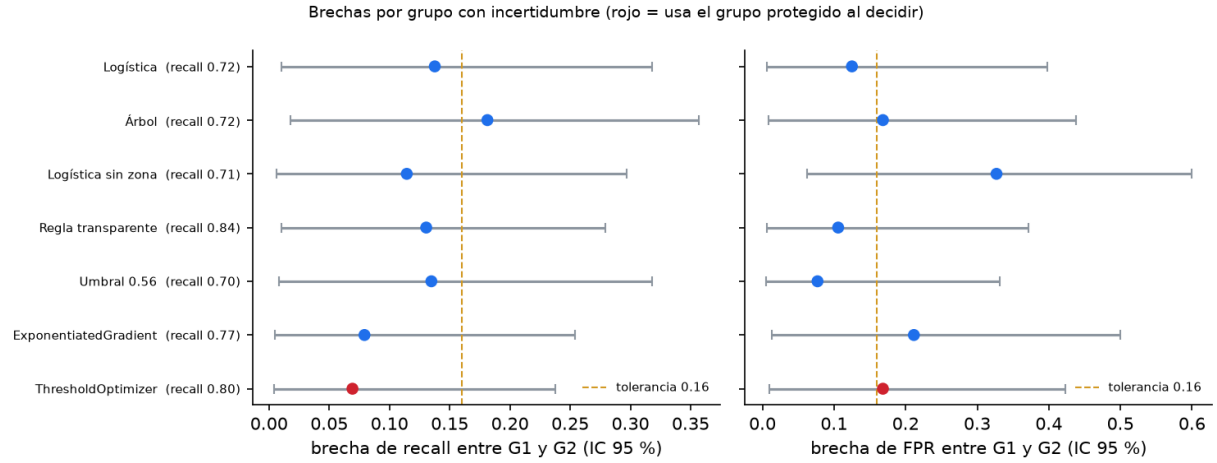
El promedio oculta una falla localizada: con un recall global aceptable (0.717), los casos de riesgo real de G1 se detectan menos (0.653) que los de G2 (0.791). A la vez, G2 recibe más falsas alertas (0.375 frente a 0.250). Ambas brechas cumplen las puertas del curso, que exigen 0.16 o menos, pero esa lectura es incompleta.

Incertidumbre de las brechas

Para estimar la incertidumbre se remuestreó cada grupo 2 000 veces por bootstrap (Efron y Tibshirani, 1993). La brecha de recall es 0.138 con un intervalo del 95 % entre 0.010 y 0.318; la de FPR es 0.125, entre 0.006 y 0.398. Con 59 casos en G2, los datos son compatibles tanto con una brecha mínima como con una del doble de la tolerancia. Como la brecha es una diferencia absoluta, su intervalo nunca incluye el cero; por eso la decisión se apoya en el **límite superior**. Una brecha observada justifica investigar, pero no prueba por sí sola discriminación causal: puede deberse a las tasas base, al tamaño de muestra o a variables correlacionadas.

Figura 1

Brechas de recall y de FPR entre grupos para los siete candidatos, con intervalo de confianza del 95 %



Nota. Línea discontinua: tolerancia de 0.16. En rojo, el candidato que usa el grupo protegido al decidir. Fuente: *reports/e07/candidates.csv*.

Auditoría interseccional

Tabla 7

Auditoría interseccional (grupo × banda de edad) con soporte explícito

Grupo	n	Positivos	Negativos	Recall	FPR	¿Interpretable?
G1 | 18-29	18	4	14	0.75	0.14	No: soporte insuficiente
G1 | 30-44	24	16	8	0.56	0.13	Sí
G1 | 45-59	35	17	18	0.59	0.39	Sí
G1 | 60+	24	12	12	0.83	0.25	Sí
G2 | 18-29	11	8	3	0.88	0.00	No: soporte insuficiente
G2 | 30-44	14	12	2	0.67	0.50	No: soporte insuficiente
G2 | 45-59	8	6	2	1.00	0.00	No: soporte insuficiente
G2 | 60+	26	17	9	0.76	0.56	Sí

Nota. Regla documentada: n ≥ 20 y al menos 5 positivos y 5 negativos para interpretar recall y FPR. Fuente: *reports/e07/intersectional_baseline.csv*.

4 de las 8 intersecciones no tienen soporte suficiente. Por ejemplo, la FPR de G2 de 30 a 44 años (0.50) se calcula con solo 2 casos negativos, así que no significa nada. Estos grupos no se ocultan: se reportan con su advertencia y motivan la recolección de más datos (Crenshaw, 1989; Buolamwini y Gebru, 2018). Entre las intersecciones interpretables destaca G2 de 60 años o más, con la FPR más alta (0.56), y G1 de 30 a 59 años, con recall por debajo de 0.60: son los puntos que el monitoreo del piloto debe vigilar.

Mitigación y trade-offs

Tabla 8

Comparación de candidatos de mitigación (prueba)

Candidato	Recall	Brecha recall	Brecha FPR	Tamaño	Puertas	Con IC
Logística (baseline)	**0.717**	**0.138**	**0.125**	**3.6 KB**	**Sí**	**No**
Árbol	0.717	0.181	0.168	7.9 KB	No	No
Logística sin zona	0.707	0.114	0.327	3.3 KB	No	No
Regla transparente (no predictiva)	0.837	0.131	0.106	0.1 KB	Sí	No
Logística, umbral 0.56	0.696	0.135	0.077	3.6 KB	Sí	No
ExponentiatedGradient	0.772	0.079	0.212	135.1 KB	No	No
ThresholdOptimizer	0.804	0.069	0.168	101.6 KB	No	No

Nota. Puertas del curso: recall ≥ 0.68 y brechas ≤ 0.16 en la estimación puntual. Con IC: el límite superior del IC 95 % de ambas brechas también ≤ 0.16 y sin usar el grupo al decidir. Fuente: *reports/e07/gates.csv*.

Ningún candidato elimina el problema: cada mitigación traslada el daño o el costo a otro lugar, lo que confirma que no hay una victoria automática.

- **Umbral recalibrado (0.56).** Se eligió en una validación temporal dentro del entrenamiento, sin mirar la prueba. Reduce la brecha de FPR a 0.077, pero el recall baja a 0.696, casi en la puerta: va contra el daño priorizado.
- **Quitar la variable zone.** Baja la brecha de recall a 0.114, pero triplica la de FPR (0.327). Eliminar un posible proxy no garantiza equidad.
- **ExponentiatedGradient con odds igualadas** (Agarwal et al., 2018). Usa el grupo solo para entrenar y reduce la brecha de recall a 0.079, pero sube la de FPR a 0.212, ocupa 135 KB y produce decisiones aleatorizadas difíciles de explicar o apelar.
- **ThresholdOptimizer** (Hardt et al., 2016). Logra la menor brecha de recall (0.069) aplicando umbrales distintos por grupo, lo que exige usar el grupo protegido al decidir. Es trato desigual: queda **excluido**.
- **Árbol de decisión.** Ocupa el doble que la logística, no mejora el recall y falla ambas puertas. Por el criterio de Green AI (Schwartz et al., 2020) se prefiere la opción suficiente.

Decisión final: limitar

Con estos elementos, la decisión del estudiante es **LIMITAR**: autorizar un piloto acotado con la regresión logística del curso, usada solo como orden sugerido de revisión humana. No se elige desplegar porque la evidencia no permite confirmar que las brechas reales estén dentro de la tolerancia. Tampoco se elige no utilizar, porque la alternativa no predictiva satura la revisión y el sistema, con las salvaguardas descritas, no excluye a nadie. Modificar con una mitigación tampoco resuelve el problema, porque todas trasladan el daño. El registro de decisión, firmado y con responsable, establece:

- **Condiciones del piloto:** revisión humana de todos los casos, sin usar el grupo al decidir, aviso a las personas, apelación en 5 días hábiles, revisión aleatoria mensual del 5 % de los casos de baja prioridad y monitoreo mensual de brechas con IC y soporte.

- **Condición de retiro:** volver a la regla transparente si el recall cae por debajo de 0.68 o la brecha de recall supera 0.16 en dos ventanas mensuales consecutivas de al menos 100 casos; si con 200 o más casos por grupo el límite superior del IC sigue por encima de 0.16; si se detecta un uso fuera de alcance; o si la apelación falla.
- **Condición para ampliar:** con 200 o más casos por grupo, ambos límites superiores en 0.16 o menos, consulta a representantes de las personas afectadas y, si lo opera una entidad pública, la evaluación de impacto ético y de derechos y el registro que exige el Decreto 787-26.

Pruebas, reproducibilidad y repositorio

El expediente parte del proyecto base del curso sin alterar su estructura. Se corrigió un error de sintaxis en *scripts/lab11_impact.py*, que además sobrescribía el registro de decisión en cada ejecución, y se añadió matplotlib para la figura. El código nuevo está en *src/inf8239_u04/audit_extra.py* y *scripts/e07_audit.py*, que regeneran toda la evidencia de *reports/e07/* en unos seis segundos con semilla fija.

La suite contiene **24 pruebas**: las 10 del curso siguen en verde y 14 nuevas verifican, entre otras cosas, las brechas con valores calculados a mano, que el intervalo contenga la estimación, que la regla de soporte marque los grupos pequeños, que el grupo protegido nunca entre al modelo, que solo ThresholdOptimizer quede marcado por usarlo al decidir, que el registro de riesgos tenga responsable y evidencia en los riesgos críticos, que la decisión sea explícita y que la matriz normativa distinga los tres tipos de afirmación. El historial de Git registra los pasos de LAB11 y LAB12 en commits separados.

Declaración de uso de inteligencia artificial

Se utilizó **Claude** (Anthropic), modelo Claude Opus 5.5, en un entorno de ejecución en la nube. La herramienta redactó el código de auditoría extendida y sus pruebas, buscó y contrastó las fuentes normativas y bibliográficas, propuso la redacción de los insumos y documentos, y detectó el error del script del curso. Los commits del repositorio la identifican como coautora.

La IA no decidió los valores del análisis. Presentó la evidencia y las opciones con sus consecuencias, y el estudiante eligió el daño prioritario (falso negativo), la métrica principal (brecha de recall), la tolerancia (0.16 con monitoreo del intervalo) y la decisión (limitar). Los prompts relevantes fueron el enunciado del ejercicio con las guías de LAB11 y LAB12, la entrega del proyecto base y esas elecciones de valor.

Las verificaciones fueron la ejecución de las 24 pruebas y de los scripts del curso, la comprobación de que cada cifra de este documento proviene de *reports/*, y la contrastación de cada referencia con su fuente. Las correcciones se detallan en *docs/AI_USE_DECLARATION.md*: el error de sintaxis del curso, la dependencia faltante, la lectura incompleta de las puertas, la hipótesis fallida sobre la variable territorial y la limitación de fuentes del Decreto 787-26. El estudiante responde por las referencias, la interpretación normativa, el código y las conclusiones.

Conclusiones

Luego de completar el expediente se comprobó que «pasar las puertas» y «ser equitativo» no son lo mismo. La regresión logística del curso cumple los umbrales sobre la estimación puntual, pero con 59 casos en el grupo pequeño la incertidumbre es tan amplia que la brecha real podría duplicar la tolerancia. Una auditoría que solo informara el número puntual habría recomendado desplegar.

Dos resultados fueron especialmente útiles para el aprendizaje. El primero es que las mitigaciones tienen costo: cada una redujo una brecha a cambio de aumentar otra, bajar la detección, aleatorizar decisiones o usar el grupo protegido de forma inaceptable. Con tasas base distintas no es posible igualarlo todo, y elegir qué igualar es una decisión de valores, no un cálculo. El segundo es que quitar una variable sospechosa como la zona no garantiza equidad: aquí triplicó la brecha de falsas alertas.

La decisión es **limitar**: un piloto acotado, con revisión humana de todos los casos, sin usar el grupo protegido, con apelación, monitoreo con intervalos y una condición de retiro concreta. La diferencia entre obligación legal, marco voluntario y recomendación ética mostró además que, aunque hoy este sistema sintético no está obligado por ninguna norma, el nuevo Decreto 787-26 haría obligatoria una evaluación como esta si una entidad pública lo adoptara.

Para el trabajo final, el expediente aporta una plantilla reutilizable: ficha de propósito, interesados con poder y daño, registro de riesgos mapeado al NIST AI RMF, matriz normativa, auditoría por grupo e interseccional con soporte e intervalos, comparación de mitigaciones y un registro de decisión con condiciones de retiro y de ampliación.

Referencias

Normativa y marcos de gobernanza

Congreso Nacional de la República Dominicana. (2013). *Ley núm. 172-13 sobre Protección de Datos de Carácter Personal*. Gaceta Oficial núm. 10737.

Constitución de la República Dominicana. (2015). Artículos 39, 44 y 70. Gaceta Oficial núm. 10805.

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)* (NIST AI 100-1). https://doi.org/10.6028/NIST.AI.100-1

OECD. (2019). *Recommendation of the Council on Artificial Intelligence* (OECD/LEGAL/0449). https://doi.org/10.1787/cc2e1d3e-en

Presidencia de la República Dominicana. (2023). *Decreto núm. 498-23 que aprueba la Estrategia Nacional de Inteligencia Artificial*.

Presidencia de la República Dominicana. (2026, 3 de noviembre). *El Gobierno aprueba el Código de Ética de la Inteligencia Artificial para garantizar un Estado digital más justo y transparente* [Decreto núm. 787-26]. https://www.presidencia.gob.do/noticias/el-gobierno-aprueba-el-codigo-de-etica-de-la-inteligencia-artificial-para-garantizar-un

Senado de la República Dominicana. (2026). *Comisión de Educación Superior continúa estudio de proyectos sobre Inteligencia Artificial*. https://www.senadord.gob.do/comision-de-educacion-superior-continua-estudio-de-proyectos-sobre-inteligencia-artificial/

UNESCO. (2021). *Recommendation on the ethics of artificial intelligence*. UNESCO.

Unión Europea. (2024). Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial. *Diario Oficial de la Unión Europea*, L, 12.7.2024.

Equidad algorítmica y evaluación

Agarwal, A., Beygelzimer, A., Dudík, M., Langford, J., & Wallach, H. (2018). A reductions approach to fair classification. *Proceedings of the 35th International Conference on Machine Learning*, PMLR 80, 60–69.

Buolamwini, J., & Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, PMLR 81, 77–91.

Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data, 5*(2), 153–163.

Crenshaw, K. (1989). Demarginalizing the intersection of race and sex. *University of Chicago Legal Forum, 1989*(1), 139–167.

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. *Advances in Neural Information Processing Systems, 29*, 3315–3323.

Kleinberg, J., Mullainathan, S., & Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. *8th Innovations in Theoretical Computer Science Conference*, LIPIcs 67, 43:1–43:23.

Weerts, H., Dudík, M., Edgar, R., Jalali, A., Lutz, R., & Madaio, M. (2023). Fairlearn: Assessing and improving fairness of AI systems. *Journal of Machine Learning Research, 24*(257), 1–8.

Documentación y Green AI

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. *Proceedings of the Conference on Fairness, Accountability, and Transparency*, 220–229.

Schwartz, R., Dodge, J., Smith, N. A., & Etzioni, O. (2020). Green AI. *Communications of the ACM, 63*(12), 54–63.

Apéndice

Repositorio del proyecto

Los artefactos editables (ficha de impacto, interesados, registro de riesgos, RACI, decisión, matriz normativa), el código, las pruebas, la evidencia generada, la Model Card y la declaración de uso de IA se encuentran en el repositorio de GitHub del proyecto:

https://github.com/melvinrivas03/inf8239-u04-e07-equidad

Para reproducir los resultados: *uv sync --frozen*, *uv run pytest -q*, *uv run python scripts/lab11_impact.py*, *uv run python scripts/lab12_audit.py --model logistic* y *uv run python scripts/e07_audit.py*.

Figura A1

Código QR de acceso al repositorio del proyecto

